

TITRE. Productrices de savoir : analyse thématique des mémoires et thèses des femmes en sciences, technologie, ingénierie et mathématiques au Québec (1985-2025)

CONTEXTE. Historiquement, l'institution qu'est l'université a été largement réservée aux hommes. Le Québec ne fait pas exception à cette réalité. Au contraire, jusqu'au 20^e siècle, les femmes ont été explicitement exclues du domaine de l'enseignement supérieur (Conseil du statut de la femme, 2008). Vers la fin des années 1970, le Conseil du statut de la femme présente sa politique d'ensemble de la condition féminine *Pour les Québécoises : égalité et indépendance* (1978), appelant, entre autres, à davantage de représentativité des femmes et de modèles féminins au sein de l'université. Malgré cet appel, **les femmes sont encore aujourd'hui sous-représentées dans plusieurs disciplines, notamment celles traditionnellement masculines comme les sciences, technologies, ingénierie et mathématiques (STIM)** (Carli et al., 2016; Chaire pour les femmes en sciences et en génie, 2022; Corbett, 2015). Pourtant, au-delà de l'évolution du nombre de femmes en STIM à travers le temps, peu est connu sur leur production scientifique concrète aux cycles supérieurs. De ce fait, malgré l'importance accordée à une plus grande inclusion des femmes en STIM, de même qu'une image de ces disciplines à travers desquelles ces dernières puissent se projeter (Cheryan et al., 2017), **aucune étude n'a documenté systématiquement l'évolution des thématiques de recherche des femmes aux cycles supérieurs dans les universités du Québec.**

OBJECTIFS. L'objectif général de ce projet est d'**offrir un portrait de l'évolution des thématiques de recherche des femmes aux études supérieures au Québec en STIM depuis les quatre dernières décennies** (1985-2025). Afin de réaliser cet objectif, **trois sous-objectifs** devront être atteints. Premièrement, nous devons *cartographier* l'ensemble de la production savante de notre corpus par thématique de recherche **(1)**. Deuxièmement, nous devons *identifier* les productions des femmes de notre corpus afin d'être en mesure de conduire des analyses sur ce sous-ensemble en particulier **(2)**. Troisièmement, nous devons *documenter* les différentes initiatives historiques et institutionnelles afin de favoriser l'inclusion des femmes dans les universités québécoises, afin de comprendre comment ces initiatives ont pu avoir un impact sur les dynamiques précédemment identifiées **(3)**.

MÉTHODOLOGIE. Pour réaliser les objectifs de cette recherche, nous appuierons sur un cadre conceptuel faisant appel l'**analyse automatique du traitement naturel** (TALN) dans le but de cartographier l'évolution de contenus scientifiques (Boyack et al., 2005; Gates et al., 2019; Moya-Anegón et al., 2007). Plus précisément, nous mobiliserons l'**analyse thématique**, une méthode computationnelle qui tire profit du fait linguistique que les mots utilisés dans un texte ne le sont pas de manière aléatoire et qu'il est donc possible d'utiliser certaines suites de mots afin de représenter le contenu sémantique de ces textes. Avec près de 100 000 mémoires et thèses publiées entre 1985 et 2025, disponibles grâce à la base de données Érudit, nous identifierons tout d'abord l'ensemble des mémoires et thèses appartenant à la catégorie STIM. Ensuite, nous classifions ce corpus à l'aide de l'algorithme d'analyse thématique BERTopic (Grootendorst, 2022). Contrairement à d'autres algorithmes d'analyse thématiques bien connus tels que LDA (Blei, 2012; Blei et al., 2003), BERTopic a l'avantage d'avoir la capacité d'identifier un thème dominant par document textuel (Egger & Yu, 2022). Cette classification permettra d'**analyser l'évolution temporelle des thématiques à travers l'ensemble des résumés** de notre corpus. Une fois cette étape de classification réalisée, nous

passerons à l'étape de la **division de notre corpus en fonction du genre**. Pour ce faire, nous utiliserons le paquet *GenderizeR* (Santamaría & Mihaljević, 2018), afin d'inférer le genre sur la base des prénoms (Larivière et al., 2013; Truc et al., 2024; West et al., 2013). Enfin, la dernière étape consistera à **analyser les dynamiques diachroniques identifiées sur la base de nos variables** (thème par année, université d'attache, programme d'études et niveau d'étude). L'évolution de ces dynamiques sera contrastée avec les politiques publiques mises en place afin de favoriser la représentation des femmes dans la poursuite dans des cursus traditionnellement masculins.

IMPORTANCE DE LA RECHERCHE. Les disparités de genre ont été bien documentées en sciences (Master et al., 2021; Sebastián-Tirado et al., 2023), notamment grâce à l'utilisation d'outils computationnels (Larivière et al., 2013; Sugimoto & Larivière, 2023). Afin de lutter contre ces disparités, le Gouvernement du Québec de même que le Fonds de recherche du Québec s'engagent mettent en place des initiatives concrètes telles que « Femmes en sciences » ou encore « Femmes et filles de sciences », s'inscrivant dans une dynamique plus large visant à « combler l'écart [de genre] en science et technologie » (CRSH, 2026; UNESCO, 2024). En continuité avec ces initiatives, **l'importance de notre recherche consiste à offrir une compréhension de la représentation des femmes en STIM au Québec plus complète**. La recherche proposée s'inscrit ainsi en **continuité avec des STIM plus équitables, diversifiés et inclusifs** (Bian et al., 2017; Carli et al., 2016; Roy et al., 2014). En ce sens, notre travail contribuera directement à mieux saisir les dynamiques de production des savoirs et de quelle manière les femmes aux cycles supérieurs en STIM ont été représentées au Québec, un aspect essentiel afin de comprendre leur représentation actuelle. Également, **la recherche contribuera directement à la découvrabilité historique des contenus scientifiques en français** (Larivière & Gaudreault-DesBiens, 2022), étant donné qu'une partie importante de notre corpus est francophone.

ÉCHÉANCIER. La recherche se divisera en trois phases et s'échelonnnera sur une période de 12 mois (Tableau 1). La première phase consistera en la **constitution de notre corpus** et son **nettoyage**. Cette phase sera la plus chronophage. La deuxième phase portera sur **l'analyse des données et des résultats**. Nous rendrons les données et résultats disponibles sur *Boréal*, une plateforme de dépôt canadien sécurisé. La dernière phase consistera à la **diffusion des résultats de la recherche**. Cette diffusion prendra plusieurs formes. Premièrement, nous écrirons un article scientifique et le rendrons disponible sur la plateforme d'archive ouverte SocArXiv. Ensuite, nous prévoyons présenter nos travaux au Colloque des cycles supérieurs du Centre interuniversitaire de recherche en science et technologie et au 94^e congrès de l'Acfas à l'Université du Québec à Montréal. Finalement, nous rendrons disponible une cartographie interactive de notre corpus par le biais d'un site web.

Tableau 1. Échéancier du projet proposé

Étapes de la recherche	M1	M2	M3	M4	M5	M6	M7	M8	M9	M10	M11	M12
<i>Constit. du corpus</i>												
<i>Analyse des données</i>												
<i>Diffusion des résultats</i>												